



USP — UNIVERSIDADE DE SÃO PAULO

Aprendizagem paramétrica e estrutural de redes
soma-produto

Candidato: Renato Lui Geh

Orientador: Prof. Dr. Denis Deratani Mauá

São Paulo

2017

1 Introdução

Aprendizado de máquina é uma área da Inteligência Artificial cujo objetivo é estatisticamente ajustar os parâmetros de um certo modelo matemático dado um conjunto de dados a fim de que seja possível fazer previsões acuradas do que se está modelando. Para isso, faz-se uso de modelos estatísticos que possibilitam, por meio de métodos computacionais, lidar com um grande número de variáveis e fazer previsões com alta taxa de acerto. Por meio da Estatística e Computação, é possível resolver um grande número de problemas cujo número de variáveis seria grande demais para humanos. Modelos probabilísticos baseados em grafos (PGM, do inglês *Probabilistic Graphical Model*), são uma classe destes modelos estatísticos em que se usa grafos para representá-los graficamente.

Os modelos probabilísticos baseados em grafos representam uma distribuição de probabilidade de forma compacta. Estes modelos representados por grafos facilitam tanto a compreensão humana ao estudá-los, quanto possibilitam que vários problemas já existentes em Teoria dos Grafos sejam utilizados como solução para problemas em PGMs. Extrair conhecimento de PGMs é análogo a extrair a probabilidade de um certo evento ocorrer dado que eventos distintos tenham ocorrido. Tal extração de conhecimento é chamada de inferência. Fazer inferência exata em PGMs clássicas, ou seja, acharmos a probabilidade exata de um certo evento, é intratável. Uma solução para este problema é utilizarmos métodos para inferência aproximada em tais modelos. No entanto, tais algoritmos aproximados são muitas vezes difíceis de analisar. Além disso, como os algoritmos de aprendizado do modelo utilizam inferência como subrotina, por consequência o aprendizado torna-se aproximado.

Redes soma-produto (SPN, de *Sum-Product Network*) são PGMs que representam uma distribuição de probabilidade tratável. Proposto em 2011, SPNs computam inferência exata em tempo linear ao número de arestas de seu grafo se obedecerem a certas propriedades [9]. SPNs apresentam uma série de características interessantes, como sua arquitetura profunda que permite representar funções de forma mais eficiente quanto mais profundo seu grafo [3]. Outras interessantes propriedades teóricas incluem uma generalização de SPNs para qualquer semi-anel em que o produto tenha escopo disjunto [6]. SPNs tiveram resultados impressionantes em diversas aplicações, como enovelamento de proteínas [5], modelagem de sinais [8], classificação e reconstrução de imagens [7, 9, 4], reconhecimento de atividade [1] e linguagem natural [2].

Neste projeto, pretende-se desenvolver uma biblioteca livre e gratuita para algoritmos de aprendizado estado-da-arte e inferência em SPNs, analisando-se experimentalmente tais algoritmos em tarefas reais, como compleição e classificação de imagens.

2 Objetivos

Os objetivos esperados neste trabalho são:

1. Domínio de conceitos sobre aprendizagem de SPNs.
2. Desenvolvimento de uma biblioteca livre e gratuita de algoritmos de aprendizado de SPNs estado-da-arte.
3. Análise experimental comparativa em tarefas reais.

3 Metodologia

A pesquisa terá seu início com o estudo dos conceitos e do estado-da-arte de SPNs, estudando-se diferentes métodos de aprendizagem de SPNs, tanto estruturais quanto relativos aos pesos do grafo.

Após o entendimento de cada algoritmo de aprendizagem, será iniciada a implementação do algoritmo na biblioteca livre e gratuita a ser desenvolvida, buscando documentar o código e elaborar relatórios. Com o desenvolvimento dos diferentes algoritmos de aprendizagem, pretende-se elaborar relatórios contendo uma comparação experimental em conjuntos de dados reais.

Durante a realização do projeto, serão elaborados documentos científicos para possível submissão a ENIAC 2017 e para o acompanhamento geral do desempenho acadêmico do candidato.

O cronograma para o desenvolvimento desta pesquisa segue abaixo.

Atividade/Mês	1º-2º	4º-5º	6º-7º	8º-10º	11º-12º
a	×				
b					
c					
d					
e					

Referências

- [1] Mohamed R. Amer e Sinisa Todorovic. “Sum-Product Networks for Activity Recognition”. Em: *IEEE Transactions on Pattern Recognition and Machine Intelligence (TPAMI 2015)* (2015).

- [2] Wei-Chen Cheng et al. “Language Modelling with Sum-Product Networks”. Em: *Annual Conference of the International Speech Communication Association 15 (INTER-SPEECH 2014)* (2014).
- [3] Olivier Delalleau e Yoshua Bengio. “Shallow vs. Deep Sum-Product Networks”. Em: *Advances in Neural Information Processing Systems 24 (NIPS 1011)* (2011).
- [4] Aaron Dennis e Dan Ventura. “Learning the Architecture of Sum-Product Networks Using Clustering on Variables”. Em: *Advances in Neural Information Processing Systems 25* (2012).
- [5] Abram L. Friesen e Pedro Domingos. “Recursive Decomposition for Non-convex Optimization”. Em: *International Joint Conference on Artificial Intelligence 24 (IJCAI 2015)* (2015).
- [6] Abram L. Friesen e Pedro Domingos. “The Sum-Product Theorem: A Foundation for Learning Tractable Models”. Em: *International Conference on Machine Learning 33 (ICML 2016)* (2016).
- [7] Robert Gens e Pedro Domingos. “Learning the Structure of Sum-Product Networks”. Em: *International Conference on Machine Learning 30* (2013).
- [8] Robert Peharz et al. “Modeling Speech with Sum-Product Networks: Application to Bandwidth Extension”. Em: *IEEE International Conference on Acoustics, Speech, and Signal Processing 39 (ICASSP 2014)* (2014).
- [9] Hoifung Poon e Pedro Domingos. “Sum-Product Networks: A New Deep Architecture”. Em: *Uncertainty in Artificial Intelligence 27* (2011).